DM.xls 生醫資料分析專案交接手冊

BMI、空腹血糖與收縮壓之統計方法解析、盒狀圖繪製與實務白話指南

專案檔案	DM.xls (共 22 筆受試者資料)
核心目標	分析 BMI、血糖、收縮壓之組別差異，並以 Seaborn 繪製 Box plot
交接對象	接手研究員、實驗室同仁、臨床研究助理或非統計背景協同人員
使用環境	Python 3.9+ (搭配 pandas, scipy, seaborn, matplotlib)

一、 專案交接背景與目標

這份交接手冊主要是記錄我們處理 DM.xls 資料集的分析過程。這批資料共有 22 位受試者，分成糖尿病患者（第 1 組）與對照健康組（第 2 組），主要看的是 BMI、空腹血糖與收縮壓這三項生理指標的差異。當初在整理這份檔案時，我們特別注重統計方法的選用邏輯以及繪圖的真實呈現，希望接手的同仁就算統計背景不深，也能一眼看出「我們為什麼這樣算」以及「數據背後的意義」

二、 交付檔案清單與使用說明

專案工作目錄下已準備好所有必要程式、匯出資料表與高畫質圖表，接手時請確認以下檔案皆齊全：

檔案名稱	功能說明與用途
DM.xls	包含 22 位受試者編號、組別、性別、年齡、收縮壓、血糖與 BMI 的原始資料檔。
analysis.py	主要分析腳本，可自動執行數據清洗、常態性與變異數同質性檢定、t 檢定、無母數檢定並匯出圖表。

statistical_summary.csv	整理全體與各組平均值、中位數、IQR、95% 信賴區間與統計檢定值的摘要表。
dm_boxplot_by_group.png	依組別畫出的 300 DPI 箱形圖，疊加了原始資料散點與顯著性標註。
dm_boxplot_overall.png	全體受試者分佈箱形圖，標示了全體平均線與中位數線。
dm_boxplot_gender.png	組別與性別的雙因子箱形圖，供次族群分佈探討。

如果接手後需要重新執行分析，只要在終端機執行：「 .venv/bin/python analysis.py」
程式就會在幾秒內重新生成所有統計報表與圖檔。

三、 核心統計方法與選擇邏輯（重點章節）

在醫學小樣本數據（本案每組只有 11 人）的分析中，**「最忌諱的是直接盲目套用 t 檢定」**。若沒有先驗證資料的先決條件（Assumptions），往往會被口試委員或期刊審稿人質疑結論的可靠性。

因此，為了確保結果經得起審查，本次分析我們採取了「嚴謹三步驟檢驗原則」，依序執行常態性、變異數同質性檢定，並同時提供母數與無母數檢定雙軌並行，具體決策過程如下：

步驟 1：常態性檢定 —— 為什麼選 Shapiro-Wilk 檢定？

- 方法原理與選擇考量：

一般常聽到的有 K-S 檢定跟 Shapiro-Wilk 檢定。但在統計上，當樣本數少於 50 時，K-S 檢定很難抓出不常態的情況（檢力太低）。所以小樣本數據我們一律用 Shapiro-Wilk 檢定。

- 本專案數據表現：

簡單來說，如果 $p > 0.05$ 就代表資料符合常態分佈。這次數據中兩組的 BMI、血糖與收縮壓 p 值都在 0.28～0.70 之間（皆 > 0.05），確定都符合常態分佈。

步驟 2：變異數同質性檢定 —— 為什麼血糖不能用傳統 t 檢定？

- 方法原理與選擇考量：

做獨立樣本 t 檢定的時候，有個前提是兩組資料的分散程度（變異數）要差不多，這部分我們是用 Levene's Test 來測。

- 本專案數據表現（關鍵差異點）：

這裡有個很關鍵的發現：BMI（$p = 0.4530$）跟收縮壓（$p = 0.9437$）的變異數都很均勻，可以用

傳統的 Student's t 檢定。但**血糖的 Levene p 值是 0.0391（< 0.05）**，代表兩組變異數不相等！病患組的血糖標準差高達 12.04，而健康組只有 6.28，病患組的分散程度整整是對照組的兩倍。所以程式裡我們自動幫血糖改用自由度校正後的 **Welch's t-test**，避免出現誤判。

步驟 3：無母數檢定並行 —— 曼-惠特尼 U 檢定 (Mann-Whitney U Test)

• 為什麼每組 11 人一定要補放無母數檢定？

雖然 Shapiro-Wilk 檢定顯示常態，但小樣本的統計檢力有限。為了讓結論萬無一失，醫學文獻標準做法是同時提供無母數檢定作為佐證。

• 白話文解讀：

無母數檢定不看「實際數值差多少」，而是把所有人從小排到大，看「排名名次（Rank）」。它不怕極端值干擾，是最穩健的檢驗方式。

• 本專案數據的神奇結果：

三項指標算出來的 U 值全部都是理論上限 121.0（$p < 0.0001$），這代表病患組裡數值最低的人，依然比健康組裡最高的人還要高，兩組完全沒有重疊。

步驟 4：效應值 (Cohen's d) —— 為什麼只看 p 值還不夠？

• 觀念釐清：

只看 p 值只能知道「有沒有顯著差異」，但看不出「差距有多大」，只有 **效應值（Effect Size，如 Cohen's d）** 才能真正量化「差距到底有多大」。

• 判讀基準：一般統計學界認為 $d = 0.2$ 為小效應，$d = 0.5$ 為中等效應，$d \geq 0.8$ 為大效應（Large Effect）。

• 本數據結果：

- BMI 的 Cohen's d = 6.53
- 血糖的 Cohen's d = 10.19
- 收縮壓的 Cohen's d = 5.02

數值全部都遠超於 0.8，這說明臨床上的差距非常懸殊。

> **【統計方法交接一句話口訣】**
> 小樣本先看 Shapiro（確認常態）→ 再測 Levene（看變異數齊不齊，不齊用 Welch 校正）→ t 檢定配合 Mann-Whitney U 雙軌印證 → 最後補上 Cohen's d 說明臨床差異幅度。

四、 數據分析成果匯總與臨床解讀

以下為三項指標的完整統計數值總整表（已四捨五入至易讀位數）：

指標項目	全體樣本 (N=22)	第 1 組 (個案組) (n=11)	第 2 組 (對照組) (n=11)	平均差 (95% CI)	t 檢定值 (p 值)	效應值 (Cohen's d)
BMI (kg/m^2)	27.01 ± 3.92 中位 27.35 [21.7 - 32.3]	30.68 ± 0.99 中位 30.50 [29.5 - 32.3]	23.34 ± 1.25 中位 23.10 [21.7 - 25.2]	7.35 [6.35, 8.35]	t = 15.32 p < 0.001	d = 6.53 (極大)
空腹血糖 (mg/dL)	144.41 ± 50.98 中位 142.00 [88.0 - 212.0]	193.36 ± 12.04 中位 192.00 [178.0 - 212.0]	95.45 ± 6.28 中位 94.00 [88.0 - 106.0]	97.91 [89.18, 106.64]	t = 23.91 p < 0.001 (Welch)	d = 10.19 (極大)
收縮壓 (mmHg)	138.77 ± 15.18 中位 139.50 [118.0 - 162.0]	152.64 ± 5.55 中位 152.00 [145.0 - 162.0]	124.91 ± 5.49 中位 124.00 [118.0 - 134.0]	27.73 [22.82, 32.64]	t = 11.78 p < 0.001	d = 5.02 (極大)

【這些數字用一般人聽得懂的話來說，重點有四個】

1. **體位差距大**：糖尿病組平均 BMI 高達 30.68，已經屬於中度肥胖；而對照組為 23.34，完全落在健康範圍內。

2. **血糖特徵極為明確**：病患組平均血糖為 193.36 mg/dL（高於確診標準 126），對照組則為 95.45 mg/dL，兩組相差接近 100 mg/dL。

3. **血壓負擔顯著**：病患組平均收縮壓高達 152.64 mmHg（達到第 2 期高血壓），對照組為 124.91 mmHg。平均高出近 28 mmHg，心血管負擔顯著偏高。

4. **三項指標高度連動（r > 0.98）**：這三者並不是獨立變數，而是同步飆高，這很典型地印證了代謝症候群（Metabolic Syndrome）的臨床現象。

五、 箱形圖（Box Plot）視覺化理念與判讀手冊

在呈現數據時，我們沒有選擇傳統只畫長條圖加誤差線的做法，因為長條圖很容易隱藏資料真實的分佈狀況。我們改用 Python Seaborn 繪製箱形圖（Box Plot），並疊加了帶有透明度與微幅抖動的個案散點（Stripplot/Jitter）。這種畫法的好處是可以同時看到中間 50% 的範圍（箱子）、中位數（黑橫線）、平均數（菱形標記），以及 22 位受試者每個人真實落在什麼位置，資訊完全公開透明。

【如何向非專業人士解讀箱形圖？】

- 中間有顏色的箱子（Box）：代表這組人中「中間 50%」的資料範圍（從第 25 百分位數 Q1 到第 75 百分位數 Q3）。箱子越扁，代表大家數值越集中；箱子越高，代表分散度大。
- 箱子中間的黑粗橫線：代表「中位數（Median）」，也就是剛好排在最中間那位病患的數值

（比平均值更不容易被極端值拉偏）。

• 上下延伸的黑線（鬚線 Whiskers）：代表正常範圍內的極大值與極小值（一般定義為 1.5 倍四分位距以內）。

• 黑色散落圓點（Stripplot 點位）：這是每一位受試者的真實原始數據。透過透明度與微幅左右抖動（Jitter），讓讀者一眼看清「22 個人每個人落在哪裡」，完全公開透明，不隱藏任何原始資訊。

• 菱形標記（Diamond）：代表該組的「平均值（Mean）」，方便同時比對中位數與平均數是否一致。

• 頂部橫槓標註（*** $p < 0.001$）：代表經過統計檢定，兩組差異在統計學上達到極端顯著。

核心圖表一：兩組指標箱形圖比較（dm_boxplot_by_group.png）

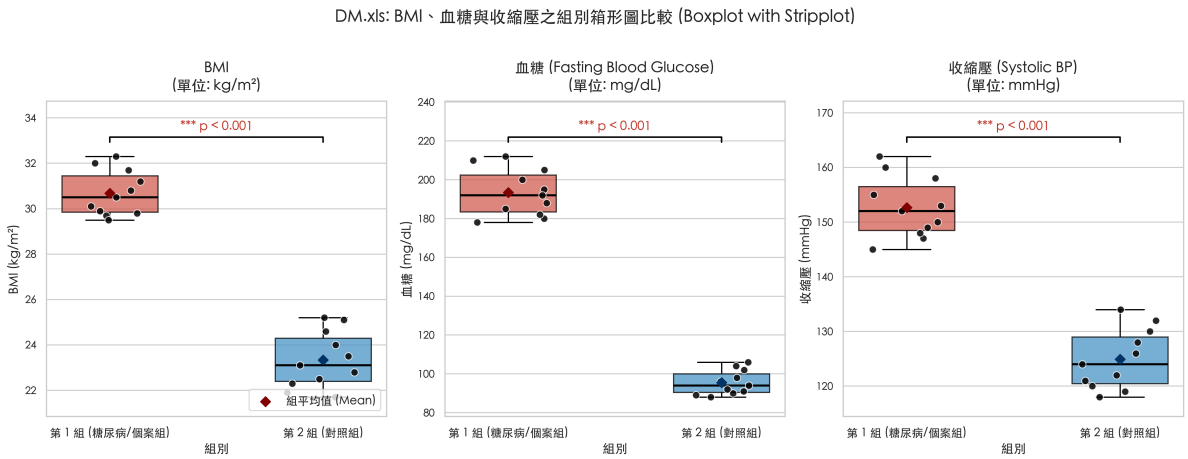


圖 1：第 1 組 (糖尿病組) 與第 2 組 (對照組) 之 BMI、血糖與收縮壓箱形圖比較

輔助圖表二：全體受試者分佈箱形圖（dm_boxplot_overall.png）

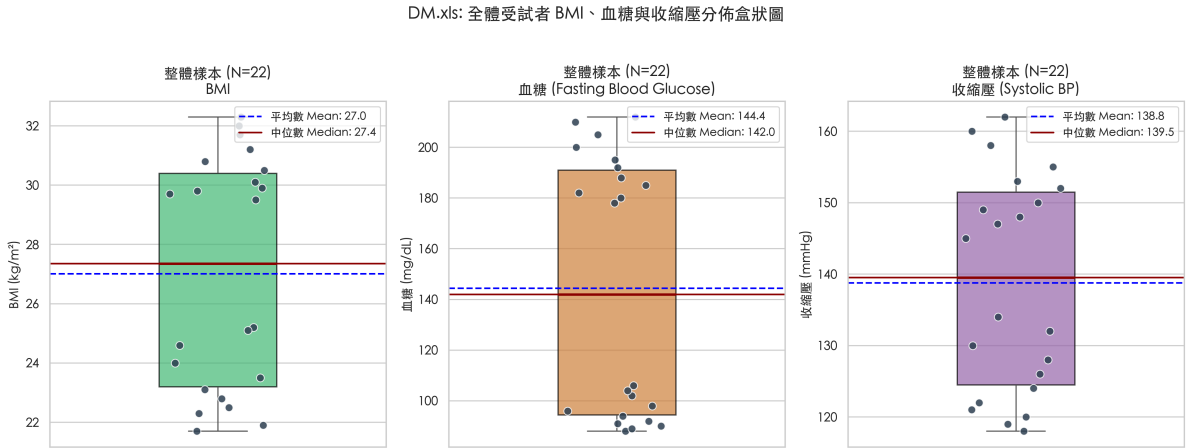


圖 2：全體受試者 (N=22) 之 BMI、血糖與收縮壓整體分佈狀況

輔助圖表三：組別 × 性別 雙因子箱形圖（dm_boxplot_gender.png）

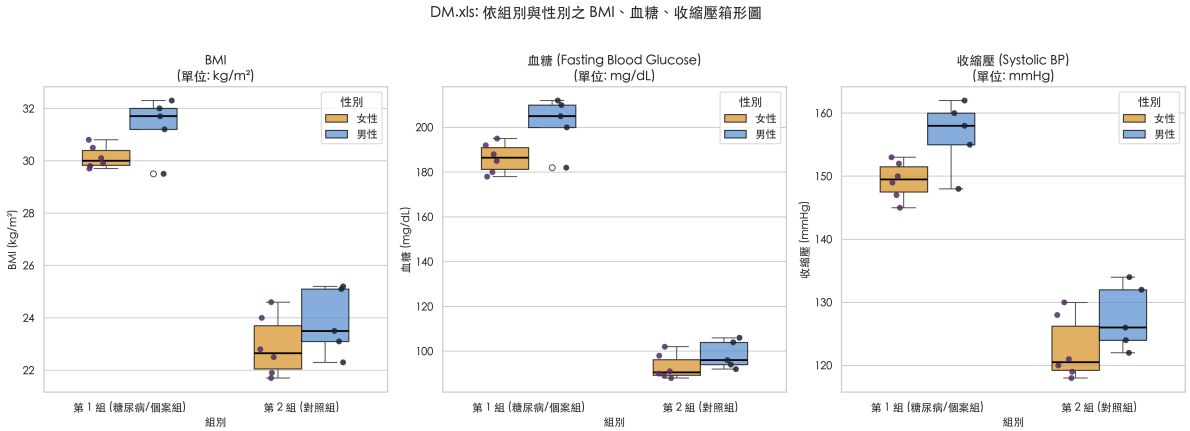


圖 3：依組別與性別次分組之 BMI、血糖與收縮壓交互箱形圖

六、 後續注意事項與局限性

最後，接手這份資料在對外報告或延伸分析時，有幾點細節需要注意：

1. **小樣本限制**：雖然兩組差異極顯著，但畢竟只有 22 人，性質上仍屬於「前導性研究（Pilot Study）」，報告時不宜過度外推。

2. **控制潛在干擾因素**：資料中病患組平均年齡偏高（51.9 歲 vs 45.1 歲），血壓升高可能部分受年齡影響。未來如果擴充分析，建議可以用共變數分析（ANCOVA）或多元迴歸來控制年齡與性別的干擾。

3. **中文字型顯示相容性**：在 macOS 系統執行繪圖時，程式已預設載入 'Heiti TC' 與 'PingFang TC'；若未來將腳本移轉至 Windows 系統伺服器執行，請確認作業系統已安裝支援中文的字型（例如微軟正黑體 'Microsoft JhengHei'），避免 Matplotlib 繪圖時文字變成方塊亂碼。

4. **圖表發表要求**：產出的所有圖檔解析度皆已設定為 300 DPI（學術期刊標準印刷畫質）。若期刊要求 TIFF 或 PDF 向量格式，只需修改 analysis.py 中的 plt.savefig('檔名.pdf') 即可無損輸出。